Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH

Instytut Informatyki

Sprawozdanie z realizacji projektu

RAG – pytania i odpowiedzi w oparciu o bazę dokumentów

Monika Jung
Numer albumu 331364

WARSZAWA 2026

Spis treści

1. Wstęp . . . 3
1.1. Opis rozwiązywanego problemu . . . 3
1.2. Dane wejściowe i oczekiwane rezultaty . . . 3
1.3. Motywacja . . . 4
1.4. Opis wkładu własnego . . . 4
2. Przegląd literatury . . . 6
3. Opis rozwiązania . . . 8
3.1. Opis wykorzystanych metod, bibliotek i narzędzi . . . 8
3.2. Opis wykorzystanych zbiorów danych . . . 9
3.3. Przebieg eksperymentów i optymalizacja . . . 9
4. Wyniki ewaluacji eksperymentalnej . . . 11
4.1. Analiza jakościowa generowanych odpowiedzi . . . 11
5. Podsumowanie . . . 19
5.1. Ocena rozwiązania problemu . . . 19
5.2. Krytyczna analiza i dyskusja . . . 19
5.3. Propozycje dalszych prac . . . 19
Bibliografia . . . 21

1. Wstęp

1.1. Opis rozwiązywanego problemu

Głównym problemem badawczym podjętym w projekcie jest zjawisko halucynacji oraz ograniczona wiedza specjalistyczna dużych modeli językowych (LLM) w wąskiej dziedzinie chemii kosmetycznej. Standardowe modele, choć dysponują szeroką wiedzą ogólną, często nie podają precyzyjnych danych dotyczących funkcji składników INCI (International Nomenclature of Cosmetic Ingredients), ich bezpieczeństwa czy pochodzenia. Celem projektu jest implementacja systemu Retrieval-Augmented Generation (RAG), który łączy generatywne zdolności modelu Llama-3.1-8B z zewnętrzną, wiarygodną bazą wiedzy, aby dostarczać precyzyjne i merytoryczne odpowiedzi na pytania użytkowników dotyczące analizy składów kosmetyków.

1.2. Dane wejściowe i oczekiwane rezultaty

System operuje na bazie danych zawierającej opisy ponad 1000 składników kosmetycznych. Są to surowe opisy składników, często zawierające terminologię chemiczną i techniczne aspekty działania.

Ingredient	**Description (excerpt)**
Butylene Glycol	Butylene glycol, or let's just call it BG, is a multi-tasking colorless, syrupy liquid. It's a great pick for creating a nice feeling product. BG's main job is usually to be a solvent for the other ingredients. Other tasks include helping the product to absorb faster and deeper into the skin (penetration enhancer), making the product spread nicely over the skin (slip agent), and attracting water (humectant) into the skin. It's an ingredient whose safety hasn't been questioned so far by anyone (at least not that we know about). BG is approved by Ecocert and is also used enthusiastically in natural products. BTW, it's also a food additive.
Potassium Sorbate	It's one of those things that help your cosmetics not to go wrong too soon , aka a preservative. It's not a strong one and doesn't really work against bacteria, but more against mold and yeast. To do that it has to break down to its active form, sorbic acid. For that to happen, there has to be water in the product and the right pH value (pH 3-4). But even if everything is right, it's not enough on its own . If you see potassium sorbate you should see some other preservative next to it too. BTW, it's also a food preservative and even has an E number, E202.

Tabela 1.1. Przykładowe wiersze bazy danych

Zamiast ogólnej odpowiedzi, system musi wygenerować precyzyjną informację opartą na faktach z bazy, zachowując przy tym naturalny język.
Przykład:

Pytanie:
What is the source of Leuconostoc/Radish Root Ferment Filtrate and what makes it a good preservative in cosmetics?
Odpowiedź:
Leuconostoc/Radish Root Ferment Filtrate is obtained by fermenting radish roots with *Leuconostoc kimchii*. The antimicrobial peptide produced during fermentation gives it preservative properties, making it a natural but milder alternative to standard chemical preservatives.

1.3. Motywacja

Wybór tematyki składników kosmetycznych wynika z rosnącej świadomości konsumenckiej. Składy produktów są skomplikowane, a nazewnictwo INCI niezrozumiałe dla laika. Motywacją do stworzenia systemu RAG w tym obszarze jest:

- Eliminacja "zmyślania"faktów przez LLM (halucynacje).
- Możliwość dostarczenia fachowej wiedzy bez konieczności kosztownego dotrenowywania (fine-tuning) całego modelu.
- Stworzenie asystenta, który w bezpieczny i przystępny sposób tłumaczy skomplikowane zagadnienia chemiczne

1.4. Opis wkładu własnego

W ramach projektu wykonano pełny proces inżynierii systemu RAG, na który złożyły się:

1. Adaptacja publicznej bazy yavuzyilmaz/cosmetic-ingredients, przygotowanie korpusu do indeksowania
2.
   - **Wariant A - bez RAG** - model typu decoder-only służący jako punkt odniesienia
   - **Wariant B - RAG + sparse retrival** - model z indeksowaniem metodą BM25, który wyszukuje najbardziej trafne fragmenty na podstawie zapytania
   - **Wariant C - RAG + dense retrival** - model z indeksowaniem przy użyciu pretrenowanego modelu embeddingów, który wyszukuje dokumenty przy użyciu indeksu wektorowego
   - **Wariant D - RAG + dense retrival + re-ranking** - model wariantu C rozszerzony o re-ranking pobranych fragmentów przy użyciu cross-encodera.
3. Przygotowanie potoku ewaluacyjnego:

- Stworzenie syntetycznego zbioru testowego (pytania i odpowiedzi wzorcowe) przy użyciu zewnętrznego modelu językowego, zapewniającego powiązanie każdego pytania z konkretnym indeksem dokumentu (ground truth).
- Automatyzacja obliczeń metryk Recall@k (ocena wyszukiwarki) oraz ROUGE-L i chrF++ (ocena jakości generowanego tekstu).

2. Przegląd literatury

Rozwój dużych modeli językowych (ang. *Large Language Models*, LLM) zrewolucjonizował przetwarzanie języka naturalnego, jednak wyzwania takie jak halucynacje oraz brak dostępu do aktualnych, specyficznych danych pozostają kluczowymi problemami badawczymi. W niniejszym rozdziale omówiono wybrane prace, które stanowią fundament dla rozwoju systemów generowania wspomaganego wyszukiwaniem (ang. *Retrieval-Augmented Generation*, RAG) oraz technik optymalizacji przepływu informacji w takich systemach.

Podstawowa koncepcja architektury RAG została sformułowana w pracy [1], gdzie autorzy zaproponowali połączenie parametrycznej pamięci modelu typu *sequence-to-sequence* z nieparametryczną bazą dokumentów (np. Wikipedia). Zrobili to za pomocą połączenia pretrenowanego retrievera z pretrenowanym generatorem oraz poddali go procesowi dostrojenia. Potok działań polega na znalezieniu top-k dokumentów dla danego zapytania przy użyciu Maximum Inner Product Search (MIPS). Wykazano wówczas, że takie podejście znacząco podnosi jakość odpowiedzi w zadaniach wymagających dużej wiedzy faktograficznej, co stanowi bezpośrednią dla niniejszego projektu w domenie składników kosmetycznych.

Ewolucja metod wyszukiwania doprowadziła do powstania systemów opartych na gęstych reprezentacjach wektorowych (*dense retrieval*). W pracy [2] przedstawiono metodę *Dense Passage Retrieval* (DPR), która wykorzystuje dwukierunkowe kodery (*bi-encoders*) do mapowania pytań i fragmentów tekstów do wspólnej przestrzeni wektorowej. Podejście to, w przeciwieństwie do metod klasycznych takich jak BM25, pozwala na wychwytywanie powiązań semantycznych, co zostało zaimplementowane w Wariancie C projektu.

Kluczowym aspektem implementacyjnym wyszukiwania semantycznego jest wydajność operacji na wektorach o wysokim wymiarze. W pracy [3] autorzy opisują architekturę biblioteki Faiss, która stanowi fundament optymalizacji wyszukiwania sąsiedztwa w przestrzeniach osadzeń (embeddings). Biblioteka ta oferuje zestaw metod indeksowania, klasteryzacji i kompresji wektorów, co pozwala na efektywne przeprowadzanie operacji *vector similarity search*. Zastosowanie Faiss w niniejszym projekcie umożliwiło realizację nieparametrycznej pamięci systemu RAG, w której lokalność wektorów bezpośrednio koduje semantykę składników kosmetycznych [3].

Kolejnym istotnym krokiem w rozwoju dziedziny było wprowadzenie modeli typu *Re-ranker*. W pracy [4] oraz w nowszych opracowaniach dotyczących modeli wskazano, że wstępnie pobrane dokumenty mogą zawierać szum informacyjny. Zastosowanie modelu typu *cross-encoder* do ponownej oceny trafności par pytanie-dokument (etap *re-ranking*) pozwala na drastyczne podniesienie precyzji, co stanowiło podstawę konstrukcji Wariantu D.

Współczesne badania koncentrują się również na ewaluacji systemów RAG. W [5] przeprowadzono kompleksowy przegląd technik RAG, dzieląc je na nurty *Naive*, *Advanced* oraz *Modular*. Autorzy wskazują, że kluczem do skuteczności jest nie tylko samo wyszuki-

wanie, ale również odpowiednie przygotowanie kontekstu oraz optymalizacja promptu. Znalazło to odzwierciedlenie w projekcie w wariancie D, w którym wdrożono techniki określane jako *Advanced RAG*, gdzie dzięki zastosowaniu re-rankingu ograniczono liczbę przekazywanych dokumentów.

3. Opis rozwiązania

W ramach projektu zrealizowano system asystenta kosmetycznego opartego na architekturze *Retrieval-Augmented Generation* (RAG). Rozwiązanie zostało zaprojektowane w sposób modułowy, zaimplementowano i porównano cztery warianty systemowe (A, B, C, D), różniące się metodą pozyskiwania i przetwarzania kontekstu.

Jako moduł generatywny użyto modelu **Llama-3.1-8B-Instruct**. Ze względu na ograniczenia zasobowe środowiska obliczeniowego (Google Colab [6]), model ten został poddany procesowi kwantyzacji 4-bitowej przy użyciu techniki *NormalFloat4* (NF4). Pozwoliło to na redukcję zapotrzebowania na pamięć VRAM przy zachowaniu wysokiej zdolności do logicznego wnioskowania i interpretacji dostarczonego kontekstu. Dodatkowo, w procesie generowania odpowiedzi dla wszystkich wariantów systemu (A, B, C, D) zastosowano stałe parametry dekodowania, aby zapewnić porównywalność wyników. Parametr temperatury (*temperature*) został ustawiony na wartość 0,1. Tak niska wartość została wybrana celowo, aby zminimalizować losowość generowanego tekstu i wymusić na modelu podejście deterministyczne.

3.1. Opis wykorzystanych metod, bibliotek i narzędzi

Do budowy systemu wykorzystano język Python oraz zestaw specjalistycznych bibliotek z ekosystemu *Hugging Face* oraz *Meta AI*:

- **PyTorch (torch):** podstawowa biblioteka wykorzystana do zarządzania operacjami na jednostkach GPU i CPU.
- **Transformers (Hugging Face):** główna biblioteka do obsługi modeli językowych. Wykorzystano wchodzące w jej skład klasy *AutoTokenizer* oraz *AutoModelForCausalLM* (dla modelu Llama) oraz *AutoModelForSequenceClassification* do precyzyjnego filtrowania wyników (re-ranking).
- **BitsAndBytes:** narzędzie zintegrowane z biblioteką *Transformers*, umożliwiające zastosowanie kwantyzacji 4-bitowej (NF4), co pozwoliło na uruchomienie modelu Llama-3.1 na sprzęcie o ograniczonej pamięci VRAM.
- **Sentence-Transformers:** użyte do implementacji modelu embeddingowego *Harrier-oss-v1-0.6b*
- **FAISS (Facebook AI Similarity Search):** biblioteka służąca do tworzenia wydajnego indeksu wektorowego i przeprowadzania wyszukiwania semantycznego metodą *IndexFlatL2*.
- **Rank-BM25:** biblioteka implementująca algorytm wyszukiwania rzadkiego (*sparse retrieval*), wykorzystana jako punkt odniesienia dla metod wektorowych.
- **Evaluate (Hugging Face):** środowisko do przeprowadzania ustandaryzowanej ewaluacji, wykorzystane do wyliczenia metryk ROUGE-L oraz chrF++, zapewniające obiektywizm wyników.
- **Narzędzia pomocnicze (Joblib, JSON, tqdm):** biblioteka *joblib* posłużyła do wydaj-

nego wczytywania bazy danych dokumentów, moduł *JSON* do zarządzania strukturą syntetycznego zbioru testowego, natomiast *tqdm* wykorzystano do monitorowania postępów długotrwałych procesów generowania i ewaluacji.

3.2. Opis wykorzystanych zbiorów danych

Głównym źródłem wiedzy dla systemu jest publicznie dostępny zbiór danych *cosmetic-ingredients*, zawierający szczegółowe opisy chemiczne i kosmetyczne ponad 1000 substancji INCI

Przygotowanie danych i ewaluacja: W projekcie nie przeprowadzano tradycyjnego procesu *fine-tuningu* (dostrajania wag modelu), dlatego nie stosowano klasycznego podziału na zbiór treningowy i walidacyjny. Zamiast tego, wkład własny obejmował stworzenie autorskiego syntetycznego zbioru testowego o wielkości 50 rekordów (do testów finalnie użyto 40 z nich, z powodu długiego czasu inferencji). Zbiór ten został wygenerowany przy użyciu zewnętrznego modelu językowego (**Qwen2.5-7B-Instruct**), który na podstawie losowo wybranych dokumentów z bazy stworzył pary: *pytanie – odpowiedź wzorcowa*. Każdy rekord testowy zawierał również unikalny identyfikator dokumentu źródłowego (*ground truth index*), co umożliwiło precyzyjne wyliczenie metryki **Recall@k**.Każdy dokument w bazie odpowiada dokładnie jednej substancji INCI. Taka struktura bazy danych zapewnia, że informacje o danym składniku nie nakładają się na siebie w różnych rekordach, co znacząco ułatwia proces wyszukiwania precyzyjnego i eliminuje ryzyko dostarczenia sprzecznych fragmentów kontekstu do modelu językowego. Warto podkreślić, że ze względu na specyfikę zbioru danych, w którym najdłuższy dokument po tokenizacji liczy 1945 tokenów, nie było konieczności stosowania techniki dzielenia tekstów na mniejsze fragmenty (ang. *chunking*). Decyzja ta została poparta analizą ograniczeń technicznych wszystkich wykorzystanych modeli:

- Główny model językowy **Llama-3.1** posiada okno kontekstowe o rozmiarze 131,072 tokenów.
- Model embeddingowy **Harrier-oss-v1-0.6b** obsługuje sekwencje do 32,768 tokenów.
- Model re-rankujący **BGE-reranker-v2-m3** posiada limit 8,192 tokenów.

Ponieważ każdy z wymienionych modeli jest w stanie przetworzyć najdłuższy rekord z bazy w całości, możliwe było zachowanie pełnej spójności semantycznej dokumentów.

3.3. Przebieg eksperymentów i optymalizacja

Zamiast monitorowania parametrów treningu (funkcji straty), skupiono się na optymalizacji procesu inferencji i wyszukiwania. W wariancie D (najbardziej zaawansowanym) zaimplementowano dwuetapowy potok:

1. **Retriever:** Pobiera top-5 najbardziej zbliżonych wektorowo dokumentów z indeksu FAISS.

2. **Reranker:** Wykorzystuje model typu *cross-encoder* do analizy interakcji między pytaniem a pobranymi fragmentami, wybierając top-3 o najwyższym wyniku trafności.

Takie podejście pozwoliło na redukcję szumu informacyjnego dostarczanego do modelu LLM, co bezpośrednio przełożyło się na wzrost jakości generowanych odpowiedzi, mierzony metrykami ROUGE-L oraz chrF++.

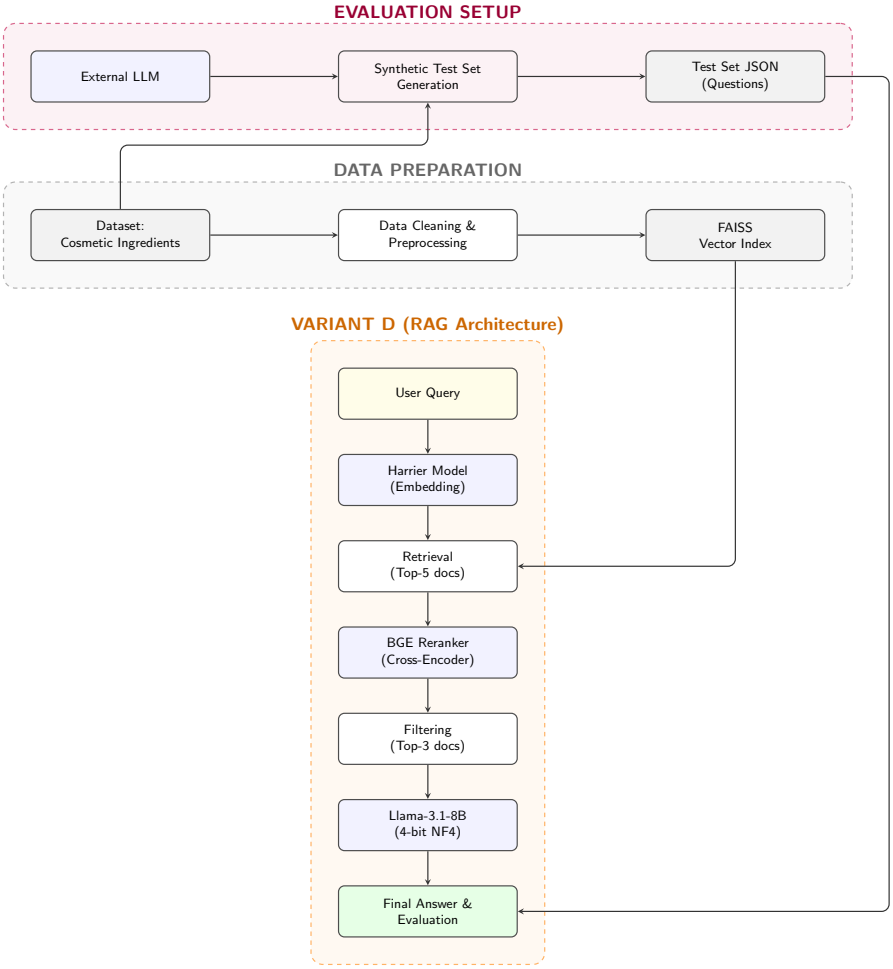

Rysunek 3.1. Architektura systemu RAG w wariancie D

4. Wyniki ewaluacji eksperymentalnej

W poniższej tabeli zestawiono zbiorcze wyniki uzyskane dla wszystkich czterech wariantów systemu. Ewaluacja została przeprowadzona na syntetycznym zbiorze testowym ($n = 40$), a uzyskane wartości stanowią średnią dla wszystkich zapytań.

Wariant systemu	**ROUGE-L**	**chrF++**	**Recall@k**
Wariant A (Baseline — bez RAG)	0.1497	32.894	–
Wariant B (BM25)	0.4759	59.074	0.8500 (k=5)
Wariant C (Dense Retrieval)	0.5064	61.7682	0.9500 (k=5)
Wariant D (Dense + Reranking)	**0.5134**	**62.5006**	**0.9750 (k=3)**

Tabela 4.1. Zestawienie metryk jakości dla poszczególnych wariantów systemu.

4.1. Analiza jakościowa generowanych odpowiedzi

W celu zobrazowania różnic w działaniu poszczególnych wariantów, w poniższych tabelach przedstawiono przykładowe zapytania ze zbioru testowego wraz z odpowiedziami wygenerowanymi przez każdy z modeli. Szczegółowa analiza odpowiedzi wygenerowanych przez poszczególne warianty systemu pozwala na sformułowanie następujących obserwacji dotyczących jakości generowanego tekstu oraz skuteczności procesów wyszukiwania:

1. **Zjawisko halucynacji w modelu bazowym (Wariant A):** Choć Wariant A generuje odpowiedzi najbardziej obszerne i poprawne gramatycznie, wykazuje on silną tendencję do tzw. halucynacji. W przykładzie dotyczącym *Serine*, model błędnie sugeruje, że składnik ten ma właściwości antyoksydacyjne lub zwiększa produkcję kolagenu, podczas gdy wiedza dziedzinowa tego nie potwierdza. Model ten "zgaduje"funkcje na podstawie ogólnej wiedzy o aminokwasach, zamiast przyznać się do braku precyzyjnych danych.
2. **Precyzja faktograficzna systemów RAG:** Warianty B, C i D wykazują znacznie wyższą wierność źródłom. W pytaniu o *Symphytum Officinale*, systemy te poprawnie przytoczyły specyficzne wartości liczbowe (100 μg/day) oraz ramy czasowe regulacji prawnych w Niemczech, których model bazowy nie był w stanie podać. Świadczy to o skuteczności zaimplementowanego mechanizmu dostarczania wiedzy nieparametrycznej.
3. **Wyzwania etapu wyszukiwania (Retrieval):** Przykłady dotyczące *Sodium Butyroyl Hyaluronate* oraz *Phenoxyethanol* w wariancie B ujawniają słabość systemów RAG – jeśli etap wyszukiwania nie zwróci odpowiedniego dokumentu (odpowiedź "I don't know"), generator nie jest w stanie udzielić odpowiedzi, nawet jeśli model bazowy posiada pewną wiedzę ogólną na ten temat.

4. **Przewaga Wariantu D (Reranking):** Wariant D wykazuje najlepszy balans między zwięzłością a merytorycznością. W przykładzie z kwasem palmitynowym, model ten w sposób strukturalny (wypunktowanie) przedstawił wszystkie trzy typy produktów wymienione w dokumencie źródłowym, podczas gdy warianty B i C pominęły część informacji lub sformułowały je w sposób mniej przejrzysty.
5. **Dostosowanie do intencji pytania:** Warianty oparte na gęstym wyszukiwaniu (C i D) lepiej radzą sobie z wyłuskiwaniem konkretnych funkcji technicznych składników, takich jak "soft focus agent"dla *Polymethylsilsesquioxane*, co jest kluczowe w profesjonalnej analizie składów kosmetycznych.
6. **Analiza stosunku jakości do kosztu obliczeniowego:** Porównanie wariantów C i D wykazuje, że mimo nieznacznej poprawy metryk lingwistycznych w wariancie D, różnica ta może nie być kluczowa w kontekście specyfiki badanego zbioru danych. Baza składająca się z około 1000 dokumentów jest relatywnie niewielka, co sprawia, że wyszukiwanie gęste (Dense Retrieval) samo w sobie jest już wysoce precyzyjne. Wprowadzenie dodatkowego etapu re-rankingu w wariancie D znacząco wydłużyło czas generowania odpowiedzi, co przy tak małym korpusie danych może być uznane za rozwiązanie nieefektywne ekonomicznie. W praktycznych zastosowaniach dla tej skali danych, wariant C oferuje najlepszy balans między wysoką jakością odpowiedzi a szybkością działania systemu.

Badania dowiodły, że dla specyficznego i relatywnie wąskiego zbioru danych, jakim jest baza składników kosmetycznych, najbardziej optymalnym rozwiązaniem okazał się Wariant C. Choć Wariant D oferuje najwyższą precyzję, jego wysoki koszt obliczeniowy i znacznie dłuższy czas przetwarzania nie przekładają się na proporcjonalnie duży wzrost jakości odpowiedzi, co czyni go rozwiązaniem mniej skalowalnym w systemach czasu rzeczywistego przy obecnej wielkości bazy wiedzy.

Cecha	Treść
Pytanie	What are some key characteristics and uses of phenoxyethanol in cosmetic products?
Oczekiwana odpowiedź	Phenoxyethanol is a safe and gentle preservative introduced around 1950, used up to 1% globally. It is stable at high temperatures (up to 85°C) and works across a broad pH range (3-10). It is often combined with ethylhexylglycerin to enhance its preservative properties and is found in various formulations.
Wariant A (Baseline)	Phenoxyethanol is a synthetic organic compound commonly used in the cosmetic industry as a solvent, preservative, and fragrance ingredient. Here are some key characteristics and uses of phenoxyethanol in cosmetic products: **Key Characteristics:** 1. **Solvent:** Phenoxyethanol is a polar solvent that can dissolve a wide range of substances, making it useful in formulations where solubilization of oils, waxes, and other ingredients is required. 2. **Preservative:** Phenoxyethanol has antimicrobial properties, which help prevent the growth of microorganisms in cosmetic products, extending their shelf life. 3. **Fragrance ingredient:** Phenoxyethanol has a mild, pleasant odor and is used to add a subtle fragrance to cosmetic products. 4. **Skin compatibility:** Phenoxyethanol is generally considered safe for use on the skin, but high concentrations may cause skin irritation in some individuals. **Uses in Cosmetic Products:** 1. **Skincare products:** Phenoxyethanol is used in moisturizers, creams, lotions, and serums to help dissolve and stabilize active ingredients, as well as to prevent the growth of microorganisms. 2. **Haircare products:**
Wariant B (BM25)	I don't know.
Wariant C (Dense)	Phenoxyethanol is a preservative that is: * Safe and gentle * Not a paraben * Introduced around 1950 * Can be used up to 1% worldwide * Found in nature in green tea, but the version used in cosmetics is synthetic * Has great thermal stability (can be heated up to 85°C) * Works on a wide range of pH levels (pH 3-10) * Often used together with ethylhexylglycerin to improve preservative activity
Wariant D (Reranking)	Phenoxyethanol is a gentle and safe preservative that has been used in cosmetics since around 1950. It can be used up to 1% worldwide. Some key characteristics and uses of phenoxyethanol include: 1. Thermal stability: It can be heated up to 85°C. 2. Wide pH range: It works on a wide range of pH levels (pH 3-10). 3. Gentle to the skin: It has a good safety profile and is suitable for use in cosmetic products. 4. Preservative activity: It can be used together with ethylhexylglycerin to improve its preservative activity. 5. Multi-tasking: It can be used in various types of formulations.

Cecha	**Treść**
Pytanie	What is the main claimed benefit of Sodium Butyroyl Hyaluronate in cosmetic products?
Oczekiwana odpowiedź	It provides long-lasting moisturizing effects and enhances skin elasticity.
Wariant A (Baseline)	Prediction Sodium Butyroyl Hyaluronate is a derivative of hyaluronic acid, a naturally occurring polysaccharide found in the body. The main claimed benefits of Sodium Butyroyl Hyaluronate in cosmetic products include: 1. **Moisturizing and Hydrating**: It helps to retain moisture in the skin, leaving it feeling soft, supple, and hydrated. 2. **Anti-Aging**: By improving skin elasticity and firmness, it reduces the appearance of fine lines and wrinkles, giving the skin a more youthful appearance. 3. **Skin Barrier Repair**: It helps to repair and restore the skin's natural barrier function, making it more resistant to environmental stressors and irritants. 4. **Improved Skin Elasticity**: It enhances skin elasticity, allowing it to snap back into place more easily, reducing the appearance of sagging skin. 5. **Anti-Inflammatory**: It has anti-inflammatory properties, which can help soothe and calm irritated skin. Overall, Sodium Butyroyl Hyaluronate is often used in skincare products to provide long-lasting hydration, improve skin texture, and reduce the signs of aging
Wariant B (BM25)	I don't know.
Wariant C (Dense)	I don't know.
Wariant D (Reranking)	I don't know.

Cecha	**Treść**
Pytanie	What role does serine play in skincare products and how is it beneficial for the skin?
Oczekiwana odpowiedź	Serine plays a role in skincare products as a moisturizing and water-binding ingredient. It is beneficial for the skin by helping with proper hydration, although specific benefits of serine are not extensively documented.
Wariant A (Baseline)	Sorbitol, not serine, is a common ingredient in skincare products. However, I assume you meant to ask about serine, which is a less common ingredient. Serine is an amino acid, a building block of proteins, and a derivative of the amino acid serine. In skincare products, serine plays a role in various functions: 1. **Moisturizing and humectant properties**: Serine can help retain moisture in the skin, making it an effective humectant. It attracts and retains water, leaving the skin feeling soft and supple. 2. **Antioxidant properties**: Serine has antioxidant properties, which help protect the skin from environmental stressors, such as pollution and UV radiation, that can cause oxidative stress and damage to the skin. 3. **Skin soothing and calming**: Serine may help soothe and calm irritated skin, reducing redness and inflammation. 4. **Improving skin elasticity**: Serine can help improve skin elasticity by increasing the production of collagen, a protein that gives skin its strength and firmness. However, it's essential to note that serine is not as widely used as other skincare ingredients, and its benefits may not be as well-documented as those of other amino acids like glyc
Wariant B (BM25)	Serine is an amino acid that serves as a water-binding ingredient in skincare products. It's a non-essential amino acid that our body can synthesize, and it plays a role in proper skin hydration. However, there is not much information available about what specifically serine can do for the skin.
Wariant C (Dense)	Serine is an amino acid that serves as a water-binding ingredient in skincare products. It's part of a moisturizing complex, but there isn't much information available about its specific benefits for the skin.
Wariant D (Reranking)	I don't know.

Cecha	**Treść**
Pytanie	What is the primary function of Polymethylsilsesquioxane in cosmetic formulations?
Oczekiwana odpowiedź	Polymethylsilsesquioxane is used as a texture enhancer and soft focus agent, providing a silicone-like softness and acting as a temporary wrinkle filler.
Wariant A (Baseline)	Polymethylsilsesquioxane (PMSQ) is a type of silicone-based ingredient commonly used in cosmetic formulations. Its primary functions include: 1. **Emollience and moisturization**: PMSQ helps to fill in the gaps between skin cells, providing a smooth, even texture and improving the skin's hydration levels. 2. **Viscosity control**: It can adjust the viscosity of formulations, making them more spreadable and easier to apply. 3. **Stability and suspension**: PMSQ can help stabilize suspensions and emulsions in cosmetic products, ensuring that the ingredients remain evenly distributed and don't separate over time. 4. **Skin feel and texture**: PMSQ can improve the skin's feel and texture, making it feel softer, smoother, and more supple. 5. **Antifoaming and antifoam properties**: PMSQ can help reduce foam formation and prevent foaming in certain cosmetic products, such as creams and lotions. 6. **Antioxidant properties**: Some studies suggest that PMSQ may have antioxidant properties, which can help protect the skin from environmental stressors and damage. Overall, Polymethylsilsesquioxane is a versatile ingredient that
Wariant B (BM25)	I don't know.
Wariant C (Dense)	he primary function of Polymethylsilsesquioxane is a texture enhancer and soft focus agent, and it also works as a (temporary) wrinkle filler.
Wariant D (Reranking)	The primary function of Polymethylsilsesquioxane in cosmetic formulations is a texture enhancer and soft focus agent.

Cecha	**Treść**
Pytanie	What is the primary function of palmitic acid in skincare products, and in what types of products can it be found according to the document content?
Oczekiwana odpowiedź	Palmitic acid serves as an emollient, making the skin feel smooth in moisturizers, and it acts as a foam building cleansing agent in cleansers. It can be found in moisturizers and cleansers, as well as in shaving foams.
Wariant A (Baseline)	Palmitic acid is a type of fatty acid that serves as an emollient and emulsifier in skincare products. Its primary functions include: 1. **Moisturizing and hydrating the skin**: Palmitic acid helps to lock in moisture and soothe dry skin, making it an excellent ingredient for hydrating and nourishing the skin. 2. **Stabilizing emulsions**: As an emulsifier, palmitic acid helps to mix oil and water-based ingredients together, creating a stable and consistent product texture. 3. **Antioxidant properties**: Palmitic acid has antioxidant properties, which help protect the skin from environmental stressors and damage caused by free radicals. Palmitic acid can be found in various skincare products, including: 1. **Moisturizers and creams**: Palmitic acid is often used in rich and nourishing moisturizers to provide long-lasting hydration and hydration. 2. **Body lotions and body butters**: Palmitic acid helps to soften and hydrate dry skin, making it an excellent ingredient for body lotions and body butters. 3. **Face creams and serums**: Palmitic acid can be used in face creams and serums to provide
Wariant B (BM25)	I don't know.
Wariant C (Dense)	According to the context, the primary function of palmitic acid in skincare products is that it can make the skin feel nice and smooth in moisturizers (emollient) or it can act as a foam building cleansing agent in cleansers.
Wariant D (Reranking)	According to the context, the primary function of palmitic acid in skincare products is to make the skin feel nice and smooth, and it can be found in two types of products: 1. Moisturizers (emollients) 2. Cleansers (as a foam building cleansing agent) 3. Shaving foams

Cecha	Treść
Pytanie	What are the potential risks associated with Symphytum Officinale Root Extract in cosmetics and how are they regulated in Germany?
Oczekiwana odpowiedź	Symphytum Officinale Root Extract contains pyrrolizidine alkaloids (PA), which have proven toxic effects. In Germany, the permissible dose of PA is 100 g/day, and treatments with PA are limited to 4-6 weeks per year if the dose is between 10-100 g/day. However, the actual content in skincare products is likely to be much lower than the threshold level, such as 0.35 g/g in a German sport-ointment, ensuring safety for use.
Wariant A (Baseline)	Symphytum officinale, also known as comfrey, is a plant that has been used in traditional medicine for its anti-inflammatory and wound-healing properties. However, its use in cosmetics has raised concerns due to potential risks associated with its toxicity. **Potential Risks:** 1. **Toxicity:** Comfrey contains pyrrolizidine alkaloids (PAs), which are toxic to the liver and can cause liver damage, cancer, and other health issues if ingested in large quantities. While the risk of skin absorption is considered low, there is still a potential for systemic toxicity if the extract is not properly formulated or if the skin barrier is compromised. 2. **Phototoxicity:** Comfrey extract may cause phototoxicity, which is the production of toxic compounds when exposed to sunlight. This can lead to skin irritation, redness, and even skin cancer. 3. **Allergic reactions:** Some individuals may be allergic to comfrey, which can cause skin irritation, redness, and itching. **Regulation in Germany:** In Germany, the use of comfrey in cosmetics is regulated by the Federal Institute for Risk Assessment (BfR) and the European Union's Cosmetics Regulation (EC) No 122
Wariant B (BM25)	What are the potential risks associated with Symphytum Officinale Root Extract in cosmetics and how are they regulated in Germany? prediction: The potential risk associated with Symphytum Officinale Root Extract in cosmetics is the presence of pyrrolizidine alkaloids (PA), which have proven toxic effects. In Germany, the permissible dose of PA is 100 g/day, and the treatment is limited to 4-6 weeks per year.
Wariant C (Dense)	The potential risk associated with Symphytum Officinale Root Extract in cosmetics is the presence of pyrrolizidine alkaloids (PA), which have proven toxic effects. In Germany, the permissible dose of PA is 100 g/day, and the treatment is limited to 4-6 weeks per year.
Wariant D (Reranking)	The potential risk associated with Symphytum Officinale Root Extract in cosmetics is the presence of pyrrolizidine alkaloids (PA), which have proven toxic effects. In Germany, the permissible dose of PA is 100 g/day, and the treatment is limited to 4-6 weeks per year if the dose is between 10-100 g/day.

** Uwaga: Urwane wypowiedzi w Wariancie A wynikają z osiągnięcia nałożonego limitu generowanych tokenów (max_new_tokens) podczas inferencji.*

5. Podsumowanie

Projekt składał sie z zaprojektowania oraz implementacji wielowariantowego systemu RAG, dedykowanego analizie składników kosmetycznych. Przeprowadzone eksperymenty dostarczyły dowody na przewagę metod opartych na zewnętrznych bazach wiedzy nad czystymi modelami generatywnymi.

5.1. Ocena rozwiązania problemu

Postawiony na wstępie problem - czyli podatność modeli LLM na halucynacje w specyficznych dziedzinach oraz brak dostępu do niszowych danych chemicznych — został skutecznie rozwiązany.

- System w najwyższym wariancie osiągnął wynik **ROUGE-L na poziomie 0,5134**.
- Udało się wyeliminować błędy merytoryczne modelu bazowego, zastępując je precyzyjnymi danymi liczbowymi i prawnymi pobieranymi z bazy dokumentów w czasie rzeczywistym.

5.2. Krytyczna analiza i dyskusja

Analiza odpowiedzi modelu oraz metryk wykazała zależności między złożonością systemu a jego wydajnością:

1. **Efektywność kosztowa:** Porównanie Wariantu C (Dense) i D (Reranking) pokazało, że przy stosunkowo małej bazie danych (ok. 1000 rekordów), zysk z zastosowania kosztownego obliczeniowo re-rankera jest marginalny. Wariant C oferował niemal identyczną trafność przy znacznie niższych opóźnieniach (*latency*), co czyni go bardziej optymalnym wyborem dla obecnej skali projektu.
2. **Zależność od jakości wyszukiwania:** Przykłady, w których systemy RAG odpowiedziały „I don't know", mimo posiadania wiedzy ogólnej przez model bazowy, wskazują na tzw. „wąskie gardło" etapu *retrieval*. Jeśli dokument nie zostanie odnaleziony, system staje się bezużyteczny, co jest główną słabością architektury RAG w porównaniu do modeli douczanych (fine-tuning).
3. **Ograniczenia zasobowe:** Konieczność stosowania kwantyzacji 4-bitowej, choć umożliwiła uruchomienie systemu, mogła wpłynąć na płynność i bogactwo językowe odpowiedzi.

5.3. Propozycje dalszych prac

W celu dalszego usprawnienia asystenta kosmetycznego, proponuje się następujące kierunki rozwoju:

- **Hybrydowe wyszukiwanie:** Połączenie metod BM25 (dla precyzyjnych nazw chemicznych) z wyszukiwaniem wektorowym (dla opisów funkcjonalnych) mogłoby wyeliminować błędy typu „I don't know".

- **Dostrajanie modelu (Fine-tuning):** Przeprowadzenie procesu *Instruction Fine-Tuning* na specyficznej polskiej lub angielskiej nomenklaturze chemicznej, co pozwoliłoby modelowi lepiej rozumieć strukturę dokumentów INCI.
- **Skalowanie bazy:** Rozszerzenie korpusu o dane dotyczące interakcji między składnikami (synergia i antagonizmy), co podniosłoby wartość użytkową systemu.

Bibliografia

[1] P. Lewis i in., „Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”, w *Advances in Neural Information Processing Systems (NeurIPS)*, t. 33, Curran Associates, Inc., 2020, s. 9459–9470. adr.: https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html.

[2] V. Karpukhin i in., „Dense Passage Retrieval for Open-Domain Question Answering”, w *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, Association for Computational Linguistics, 2020, s. 6769–6781. DOI: 10.18653/v1/2020.emnlp-main.550. adr.: https://aclanthology.org/2020.emnlp-main.550/.

[3] M. Douze i in., „The Faiss library”, *arXiv preprint arXiv:2401.04514*, 2024.

[4] Y. Qu i in., „RocketQA: An Optimized Training Proch to Dense Passage Retrieval for Open-Domain Question Answering”, w *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, Association for Computational Linguistics, 2021, s. 5835–5847. DOI: 10.18653/v1/2021.naacl-main.461. adr.: https://aclanthology.org/2021.naacl-main.461/.

[5] Y. Gao i in., „Retrieval-Augmented Generation for Large Language Models: A Survey”, *arXiv preprint arXiv:2312.10997*, 2024, Dostęp zdalny (25.04.2026). Kompleksowy przegląd paradygmatów RAG: Naive, Advanced i Modular. DOI: 10.48550/arXiv.2312.10997. adr.: https://arxiv.org/abs/2312.10997.

[6] Google, *Google Colab: A free cloud service based on Jupyter Notebooks*, Dostęp zdalny (25.04.2026): https://colab.research.google.com/, Platforma wykorzystana do uruchomienia i kwantyzacji dużych modeli językowych oraz implementacji systemu RAG., 2026.